Scalability

分散式系統中的可擴展性（Scalability）

什麼是可擴展性？

Scalability（可擴展性） 指的是系統能隨著需求（使用者、資料量、流量）的增加，透過增加資源來維持效能與穩定性的能力。

在分散式系統中，可擴展性是關鍵，因為使用量往往會不斷成長，我們也要確保系統在高流量下仍維持低延遲和高吞吐量。

- 吞吐量 (Throughput)：每秒能處理的請求。
- 延遲 (Latency)：請求處理所需時間。

為什麼重要？

1. **應對高流量**：使用者與請求量成長時，若架構不可擴展，可能會發生延遲、錯誤甚至宕機。
2. **成本效率**：可擴展系統能根據需求彈性增加或減少資源，避免浪費。
3. **業務成長**：產品成功後，架構必須支撐更多使用者，否則成長會成為壓力。
4. **可靠性**：分散式可擴展設計能避免單點故障，提高整體穩定度。

垂直擴展（Vertical Scaling）

假設你有一台咖啡機（伺服器），每天要幫忙沖咖啡給員工（處理請求，一開始它只有單孔濾網，一次只能沖 1 杯。當需求變大時，你換成一台更高級的咖啡機，有三孔濾網，一次能沖 3 杯（加 RAM、換更快的 CPU、用更大的硬碟）。

buildmoat.org

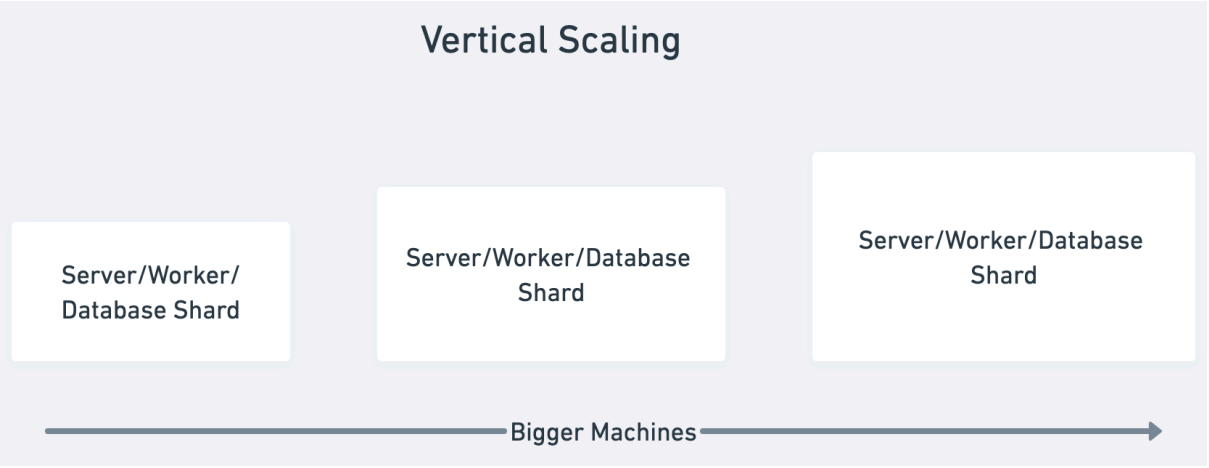

- **做法**：升級單一伺服器（增加 CPU、記憶體、硬碟）。
- **優點**：簡單、改動少。
- **缺點**：有物理上限，成本高。

水平擴展（Horizontal Scaling）

還是咖啡的例子：舊咖啡機能力有限，但員工數量增加很多。與其一直換更高級的咖啡機，不如多買幾台普通咖啡機，請更多人同時操作，一起沖咖啡（加伺服器節點，做負載平衡）。

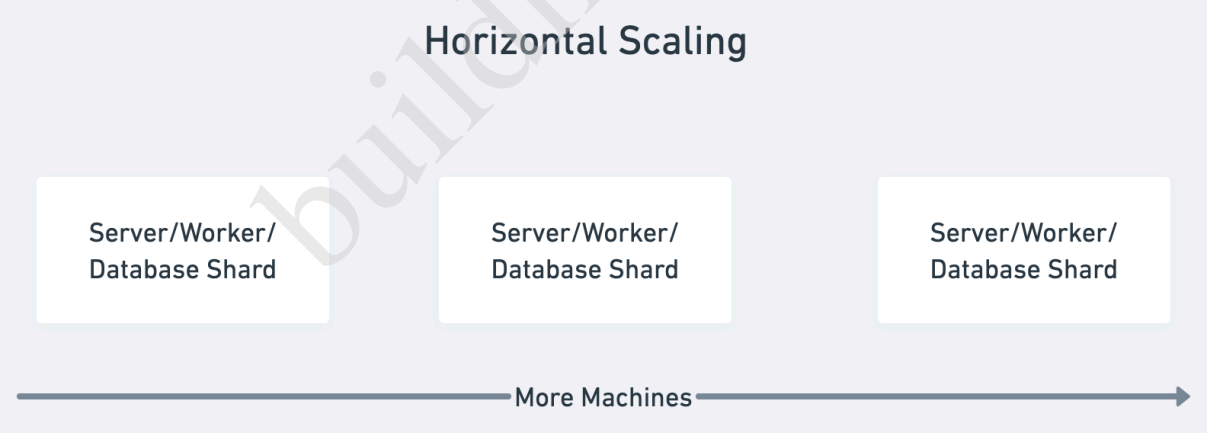

- **做法**：增加伺服器數量，透過 Load Balancer (負載平衡) 讓多台機器分擔工作。
- **優點**：理論上無限擴展，彈性佳，能應對大規模成長。
- **缺點**：系統設計複雜，需要處理分散式資料一致性等問題。

此章節的重點：

buildmoat.org

一般來說，企業會先透過垂直擴展解決短期需求，等流量持續增加時，再轉向水平擴展來支撐長期成長。

比較項目	Vertical Scaling	Horizontal Scaling
做法	升級單機	增加機器數量
上限	有物理上限	理論無限
複雜度	低	高
成本	初期低、後期貴	彈性
適合	短期、快速解法	長期、大規模

自我測驗

Q1：Throughput 和 Latency 分別指什麼？

> - **Throughput（吞吐量）**：每秒能處理的請求數量。
> - **Latency（延遲）**：單一請求從發出到完成所需的時間。

Q2：以下敘述何者正確？(A) Horizontal scaling 設計比 vertical scaling 簡單 (B) Vertical scaling 理論上沒有上限 (C) Horizontal scaling 需要處理分散式資料一致性問題 (D) 一般建議直接從 horizontal scaling 開始

> **答案：(C)**
>
> - (A) 錯 — horizontal scaling 的設計更複雜，需要 load balancer 和分散式架構。
> - (B) 錯 — vertical scaling 有物理上限（單台機器的 CPU、RAM 上限）。
> - (C) 對 — 多台機器間需要處理資料一致性。
> - (D) 錯 — 一般先用 vertical scaling 解決短期需求，再轉向 horizontal scaling。

Q3：為什麼可擴展性對業務很重要？列舉至少三個原因。

> **應對高流量**：使用者與請求量成長時，避免延遲、錯誤或宕機。**成本效率**：根據需求彈性增減資源，避免浪費。**業務成長**：架構必須支撐更多使用者。**可靠性**：分散式設計避免單點故障，提高穩定度。

buildmoat.org